Relatório 6 - Prática: Embedding (II)

Brenno Soares de Aguiar

Descrição da atividade

Nessa atividade, buscou o entrelaçamento do n8n com o embedding, os quais são respectivamente um automatizador de tarefas no code e um banco de dados vetorial gratuito, na aula pede para escolher uma forma de acessar o n8n, mas como já possuo ele instalado na minha máquina de aulas passada, optei por hospedar localmente mesmo. Durante a execução da aula, foi instruído a usar uma API KEY da OpenAI, contudo só há versões pagas para a mesma, então foi decidido usar uma do Google Gemini, o que resultou em um bom funcionamento, visto que a da OpenAI estava dando erro por não ter créditos.

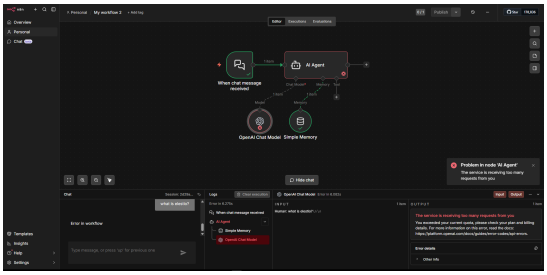

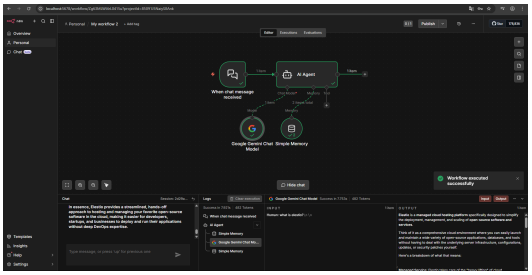

Usando apenas o modelo de linguagem e a memória simples, as perguntas eram respondidas, mas não de forma esperada, sempre vagas, como foi perguntado quantos softwares estavam disponíveis na plataforma “elestio”, a resposta era que havia muitos e recomendava navegar pelo site, contudo o esperado era que se achasse a frase que diz que há mais de 350 softwares disponíveis para uso. Foi criado um novo fluxo para colocar essa base de dados e utilizado o site “elest.io” para fazer os testes, usou-se ferramentas para analisar e retirar as informações do site, a princípio sem um “filtro” tudo estava confuso, mas usou uma ferramenta para extrair o html e através disso o que era apenas um monte de informações amontoadas ficou mais organizado e legível, o que é extremamente necessário para alimentar nossa IA posteriormente. Feito o ligamento entre nosso fluxo e o Qdrant, não utilizei o elestio, usei a chave que já havia criado anteriormente, e fiz a integração embbeding com o Gemini, que foi o modelo escolhido por mim para essa tarefa. Feito todas as etapas, a collection do elestio foi criada com sucesso:

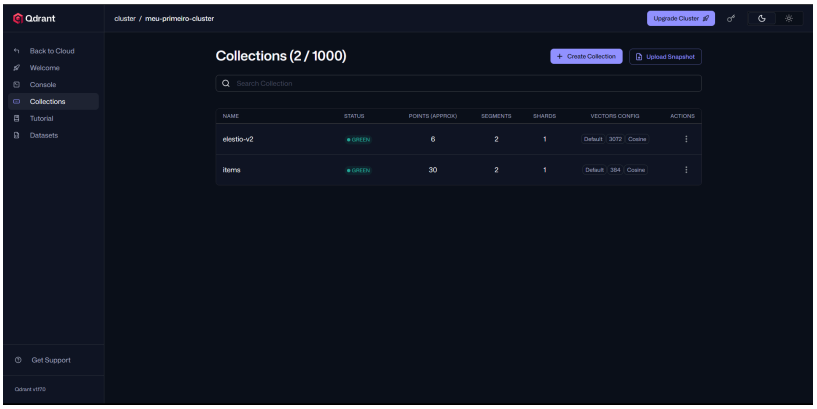

Ao final, o fluxo ficou como o esperado, contudo mesmo assim a pergunta inicial não foi respondida de forma esperada, mas abre espaço para insights de alimentacao de agentes baseado em assuntos específicos que podem ser muito úteis futuramente

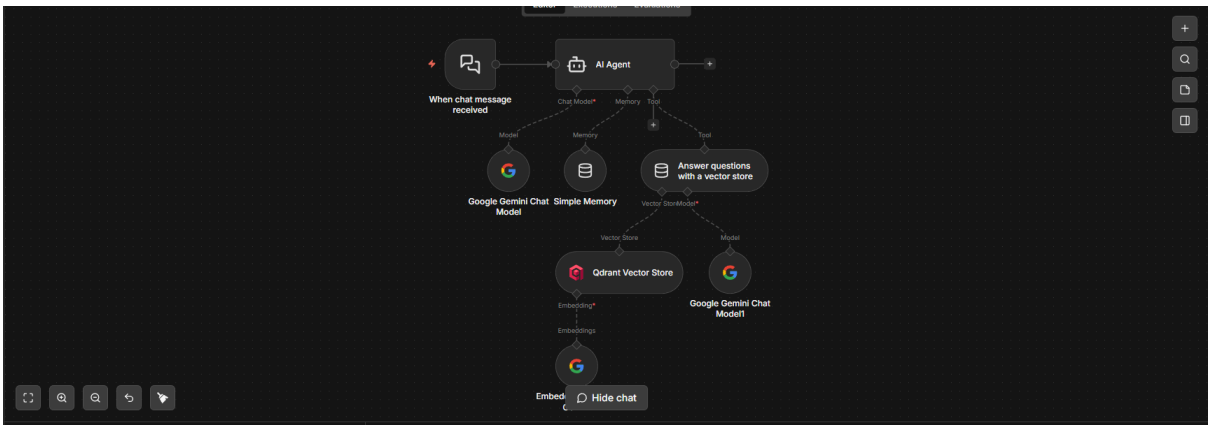

Dificuldades

A principal dificuldade foi achar uma API que não fosse paga e funcionasse perfeitamente, apesar de usar o Gemini para essa tarefa, ele se mostrou ineficiente em bastante aspectos, além do meu domínio de inglês não ser o melhor, o que dificulta acompanhar as aulas e fazer as tarefas de forma rápida

Conclusões

A alimentação de um fluxo através de outro é um caminho que tem bastante opções, vejo como na saúde, um agente especializado em uma determinada enfermidade poderia tomar decisões e sugerir tratamentos em segundo enquanto um ser humano faria o mesmo em dias ou semanas porque o agente pode consultar uma base de dados de forma excepcionalmente rápida.

Referencias

https://www.youtube.com/watch?v=cCDAY0nb0T0

https://elest.io/

https://qdrant.tech/documentation/cloud-quickstart/

https://aistudio.google.com/prompts/new_chat